# Dorain

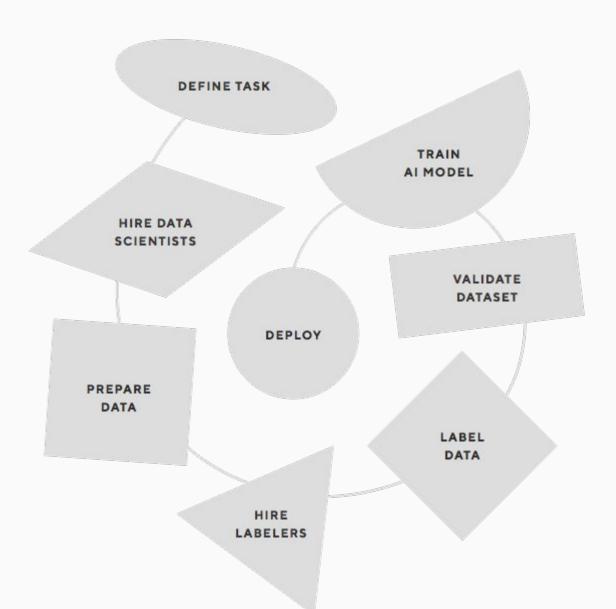
Al happens

dbrain.io

CHALLENGE

# Al development is hell

Today, bringing Al into business is a real pain. Before any Al implementation is possible, companies must invest heavily in data preparation and in hiring rare, expensive specialists — while competing with data giants like Google, Facebook, and Amazon. Onerous infrastructure and support costs further inhibit Al adoption.



**PLATFORM** 

# Best possible Al through data science competitions

Data scientists compete to build the best MVP-ready model.



Aug 20 - Sep 17, 2018

### Bear the bull

Can we leverage the machine learning tools to build augment intelligence to help crowds predict economic outcomes in arworld?

Organize



Cindicator

Competitors:

56

Prize money:

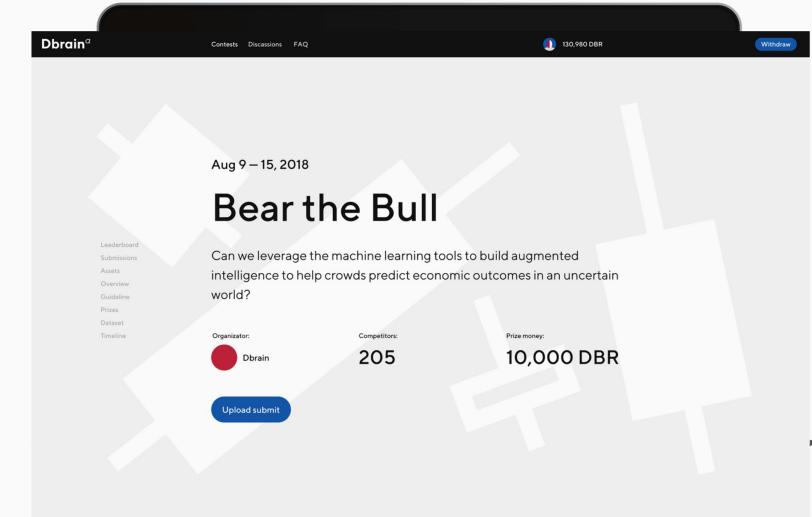
4000

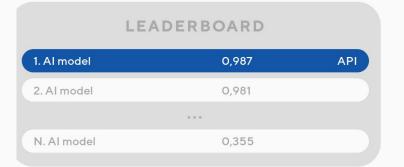
Join contest

# Best possible Al through data science competitions

- You upload the code
- We train and score the model
- Solution is available via API

Solutions are reproducible and ready for integration by default.





Dbrain enables training models with no human access to data at all. We provide a tiny part of data for data scientists to implement algorithms on it. Thus, data keeps secured and will never leak.

Могут ли люди предсказать курс Bitcoin?



Кулагин Дмитрий Менеджер проектов, Тула, Ingate



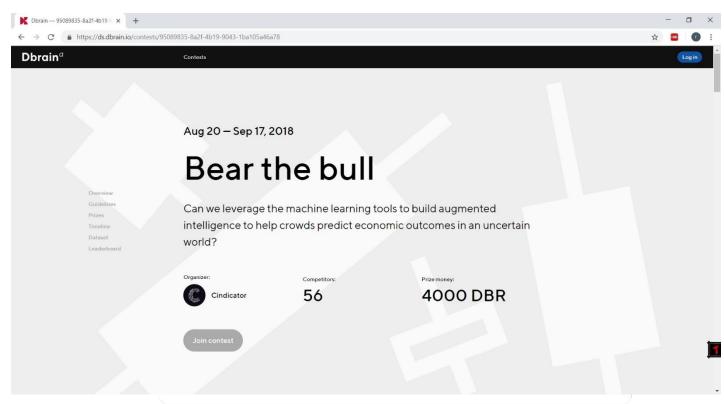
Платформа и формат	01
Задача соревнования	02
Решение и результаты	03
Прочее	04

# 01 Платформа и формат

## Платформа Dbrain

Соревнование в beta режиме, все должно работать, но могут быть сбои

Что необычно – все сабмиты финальные





### Формат сабмита

```
class DSModel:
def __init__(self, assets_dir: str, dump_dir: str):
    pass
def train(self, data_dir: str) -> None:
    pass
def dump(self) -> None:
    pass
def load(self) -> None:
    pass
def predict(self, items: [bytes]) -> [{str: {str: object}}]:
    pass
def update(self, items: [(bytes, bytes)]) -> None:
    pass
```



# 02 Задача соревнования

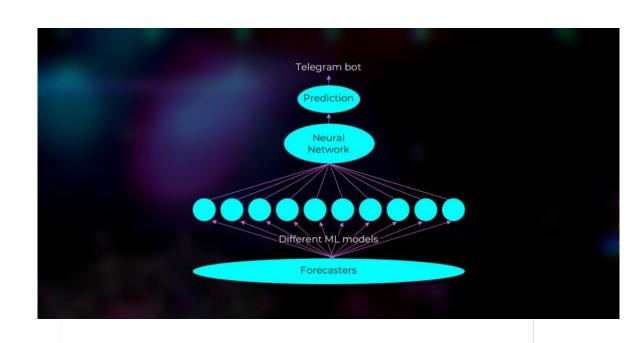
### Задача

Эксперты отвечают на вопросы вроде «Вырастет ли биткоин до 7000 до конца месяца?»

Наша задача агрегация прогнозов разных экспертов в один

#### Метрика

**Inverted balanced LogLoss** 





### Данные

**520** 

#### примеров

Общее количество примеров с известными ответами в публичной части данных.

Этот же набор используется на сервере в первичном обучении

37131

#### экспертов

Большая часть экспертов(70%) имеет менее 10 ответов в выборке.

6

#### параметров

Страна, пол(4 пола), возраст(от 320 лет до -2 недели), время начала опроса, время окончания опроса, на какой период делается прогноз



# 03 Решение и результаты

# Baseline от организаторов

## Разделяем людей на группы по точности последних прогнозов

Точность - скользящее среднее

Модель – RandomForest

Лик таргета при расчете скользящего среднего



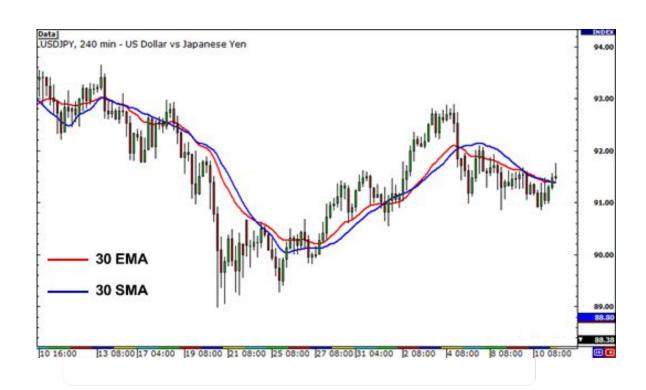


### Exponential moving average

$$\textit{EMA}_t = \alpha \cdot p_t + (1 - \alpha) \cdot \textit{EMA}_{t-1}$$

Позволяет работать со всеми экспертами без накопления минимального объема статистики

Рост CV, но снижение LB





### Валидация

Локальное повторение всего серверного процесса

Размер hold-out подбирал по 2м моделям для которых знал LB добиваясь локальной корреляции

Хватило на пяток улучшений



## Clip

	avg_0	avg_1	avg_2	count_0	count_1	count_2	median_0	median_1	median_2	target	pred	err
101	0.246058	0.225884	0.252337	137	447	184	0.070	0.00	0.000	1.0	0.301440	0.698560
3	0.175985	0.214142	0.234432	137	437	185	0.000	0.00	0.000	1.0	0.302126	0.697874



## Пол, возраст, горизонт прогноза, отдельные эксперты

Пол и сегмент возраста пробовал добавлять как параметр группировки – улучшение локально ухудшение паблика

Горизонт прогноза – краткосрочные прогнозы более точные. Разброс в данных от нескольких дней до года. Улучшение локально и паблика

Добавление прогнозов отдельных экспертов(топ 20 по количеству прогнозов). Улучшение локально ухудшение паблика

You overfit it!

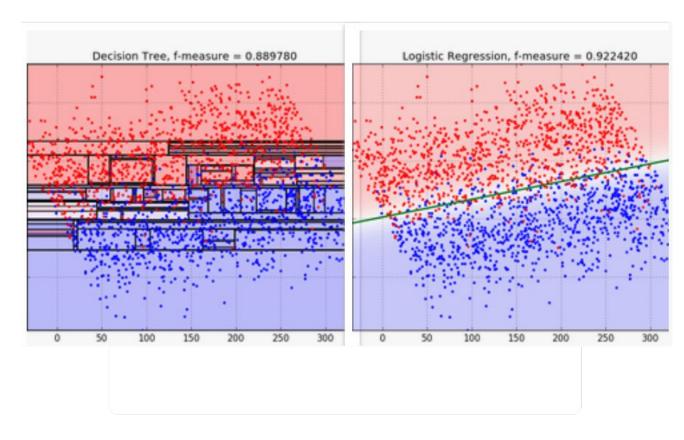


### From xgboost to logreg

Раз все оверфитится нужно пробовать слабые модели

Дало хороший прирост на локальной валидации, но на LB +- то же самое

LB best - среднее xgboost и logreg



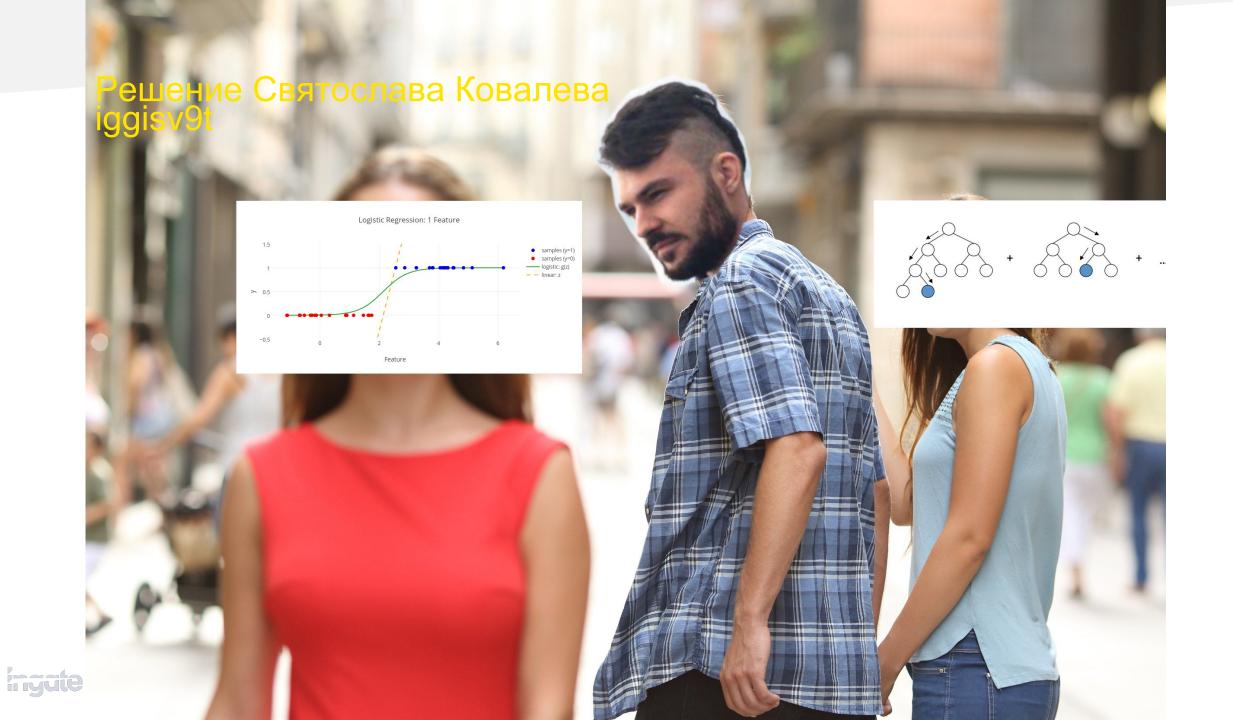


### Результаты

Rank	Username	Score	Submissions	Rank	Username	Score	Submissions
1	iggisv9t	1.7575	17	0	rekcahd	1.6562	34
2	vkim	1.7549	60	2	Lamoda_team	1.5733	43
3	sht3ch	1.6957	16	3	iggisv9t	1.5638	17
4	edmonwales	1.6150	142	4	mikeOsv	1.5628	37
5	skyby.73	1.6138	1	5	edmonwales	1.5455	142
6	hoogleraar	1.6132	18	6	sht3ch	1.5314	16
7	Lamoda_team	1.6081	43	7	isenbaev	1.5258	79
8	isenbaev	1.6073	79	8	pyybor	1.5245	4
9	mikeOsv	1.6063	37	9	[dsmlkz] sneddy	1.5037	7
10	TheRealRoman	1.5967	6	10	vkim	1.5033	60
15	rekcahd	1.5549	34				

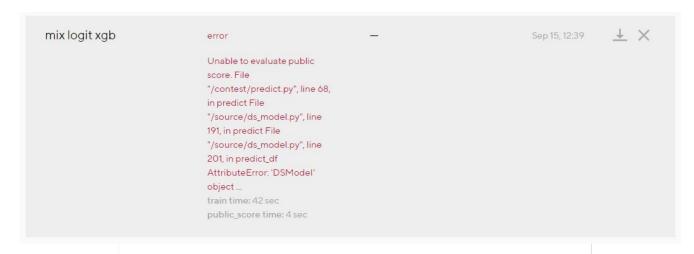


## 04 Прочее



### Ошибка в платформе

#### и вопросы морали



Используя Update можно было пробросить правильные ответы на прошлый батч в ошибке.

Часть обнаруживших ошибку сообщили организаторам, один участник решил использовать баг и был дисквалифицирован. Что привело к бурному обсуждению в ODS на тему «кто прав?», к единогласному решению не пришли



#### Так могут предсказать или нет?

Logloss(mean(target)) = 0.6712

Logloss(best\_model) = 0.6367

Разница небольшая, но в трейдинге ее вполне может хватить.

В рулетке у казино преимущество всего лишь 2,7%, и это гарантирует им хорошую прибыль



